

Análise Comparativa de Técnicas de Detecção Facial sob Variações de Iluminação para Aplicações em Segurança

Comparative Analysis of Facial Detection Techniques under Illumination Variations for Security Applications

Rafael Cândido, Lucas Tourinho, Gabriella Pereira, Lucas Rocha

Abstract—Facial detection is one of the most fundamental tasks in computer vision, with direct applications in security, access control, and surveillance. Despite significant advances in the field, illumination variation remains one of the primary practical challenges: algorithms that perform well in controlled environments frequently fail in real-world conditions, where low light, lateral illumination, or overexposure are common. This paper presents a comparative analysis of three facial detection approaches — Haar Cascade, HOG+SVM, and a lightweight Convolutional Neural Network (YuNet) — evaluated on images captured under four controlled illumination conditions. The study also investigates the impact of Contrast Limited Adaptive Histogram Equalization (CLAHE) preprocessing on each method. Experiments are conducted in Python using OpenCV and dlib, measuring precision, recall, F1-score, and average inference time per image. Results indicate that CNN-based methods are more robust to adverse lighting, while classical detectors benefit more significantly from CLAHE preprocessing.

Index Terms—Facial Detection, Image Processing, Illumination, Haar Cascade, HOG+SVM, Convolutional Neural Network, CLAHE, OpenCV, Security.

RESUMO

A detecção facial é uma das tarefas mais fundamentais em visão computacional, com aplicações diretas em segurança, controle de acesso e vigilância. Apesar dos avanços na área, a variação de iluminação ainda representa um dos principais desafios práticos. Este trabalho apresenta uma análise comparativa entre três técnicas de detecção facial — Haar Cascade, HOG+SVM e uma rede neural convolucional leve (YuNet) — avaliadas sobre imagens capturadas em quatro condições de iluminação distintas, com e sem a aplicação do pré-processamento CLAHE. Os experimentos são conduzidos em Python com as bibliotecas OpenCV e dlib.

Palavras-chave: Detecção Facial, Processamento de Imagens, Iluminação, Haar Cascade, HOG+SVM, Rede Neural Convolucional, CLAHE, OpenCV, Segurança.

I. INTRODUÇÃO

Câmeras de segurança raramente operam em condições ideais de iluminação. Ambientes internos têm fontes de luz artificiais irregulares, áreas externas estão sujeitas a contraluz, e períodos noturnos reduzem drasticamente a qualidade das imagens captadas [6]. Para que um sistema de detecção facial funcione de forma confiável nesses cenários, o detector

precisa ser robusto a essas variações — e saber exatamente em quais condições cada método falha é tão importante quanto saber quando ele funciona.

Escolhemos três detectores que representam momentos distintos da evolução da área e que estão todos disponíveis como ferramentas *open source* de fácil reprodutibilidade. O Haar Cascade de Viola e Jones [1], integrado ao OpenCV desde suas versões iniciais, foi o primeiro detector facial em tempo real e ainda é amplamente utilizado; porém, é sabidamente sensível a variações de contraste. O HOG+SVM de Dalal e Triggs [2] surgiu justamente para superar essa fragilidade, introduzindo a normalização em blocos do descritor de gradientes para conferir maior invariância local à iluminação. Por fim, o YuNet [4] representa a abordagem atual baseada em CNN leve, também integrada ao OpenCV, que aprende representações diretamente dos dados sem precisar definir manualmente quais características são discriminativas.

Essa escolha forma uma progressão natural em termos de como cada método lida com a iluminação: o Haar depende de padrões de contraste fixos, o HOG normaliza gradientes para mitigar esse efeito, e o YuNet aprende a extrair características sem essas hipóteses embutidas. Para cada um, avaliamos também o impacto do CLAHE [5] como etapa de pré-processamento, verificando se a normalização de contraste local compensa as variações de iluminação ou introduz outros problemas.

O experimento foi conduzido sobre dois datasets: um subconjunto do LFW [7] com 100 imagens classificadas por condição de iluminação e um conjunto próprio com 19 imagens capturadas pelos autores em ambiente controlado. As seções seguintes detalham a fundamentação teórica (Seção II), a metodologia (Seção III), os resultados (Seção IV), a discussão (Seção V) e as conclusões (Seção VI).

II. FUNDAMENTAÇÃO TEÓRICA

A. Haar Cascade

O principal ponto de fragilidade do Haar Cascade frente à iluminação é estrutural: o método compara somas de intensidade em regiões retangulares da imagem, o que significa que qualquer mudança no padrão de contraste local — sombras, reflexos, baixa luminosidade — pode distorcer ou apagar as características que o classificador aprendeu a reconhecer.

A estrutura proposta por Viola e Jones [1] usa imagens integrais para calcular essas somas em tempo constante, tornando o método muito eficiente. O AdaBoost seleciona as características retangulares mais discriminativas e organiza os classificadores em cascata: regiões sem rostos são descartadas nas etapas iniciais, concentrando o processamento onde há maior probabilidade de haver uma face. É essa eficiência que explica por que o método ainda é usado mais de vinte anos depois — mas ela vem com a limitação de depender de padrões de contraste fixos, aprendidos em condições específicas de iluminação.

B. HOG + SVM

O HOG+SVM surgiu em 2005 com uma motivação explícita de Dalal e Triggs [2]: criar um descritor mais robusto a variações de contraste do que os métodos baseados em comparação direta de intensidade. Em vez de somas brutas, o método calcula histogramas das orientações dos gradientes locais em células da imagem. Esses histogramas são normalizados em blocos sobrepostos, o que confere ao descritor uma invariância local a mudanças de iluminação dentro de cada bloco.

Na prática, isso significa que o HOG tolera melhor variações suaves de contraste, mas ainda pode falhar quando a iluminação é muito escura ou quando sombras fortes alteram completamente a direção dos gradientes locais. O vetor de descritores resultante é classificado por uma SVM treinada para separar faces de não-faces. Neste trabalho, usamos o detector frontal pré-treinado da biblioteca dlib, que aplica essa abordagem com janela deslizante sobre a imagem em escala de cinza.

C. YuNet

Diferentemente do Haar e do HOG, o YuNet [4] não parte de hipóteses explícitas sobre quais características de uma face são relevantes. A rede convolucional aprende essas representações diretamente dos dados de treinamento, o que a torna, em teoria, mais capaz de generalizar para condições não vistas — incluindo variações de iluminação que os métodos baseados em características manuais tendem a tratar como ruído.

O modelo foi projetado para ser leve e rápido, disponibilizado em formato ONNX e integrado ao OpenCV via `cv2.FaceDetectorYN` desde a versão 4.5.4. Em relação ao MTCNN [3], que segue a mesma linha de redes convolucionais para detecção facial, o YuNet é significativamente mais rápido. Um detalhe prático que encontramos durante a implementação: o limiar de confiança padrão do OpenCV (0.9) precisou ser ajustado para 0.7 nas imagens de alta resolução do dataset próprio, indicando que o modelo foi originalmente calibrado para imagens de dimensões menores.

D. CLAHE

Quando a iluminação de uma imagem é irregular — muito escura em algumas regiões e muito clara em outras — a equalização global de histograma tende a piorar o resultado: ao redistribuir todas as intensidades de forma uniforme, ela

super-amplifica o ruído nas regiões escuras. O CLAHE [5] resolve esse problema dividindo a imagem em blocos menores e equalizando cada um de forma independente.

Um parâmetro de limite de contraste (*clipLimit*) evita a amplificação excessiva de ruído, redistribuindo o excesso uniformemente entre os *bins* do histograma local. Neste trabalho, aplicamos o CLAHE no canal de luminosidade (Y) após conversão para o espaço YCrCb, com *clipLimit* = 2.0 e grade de 8×8 blocos, preservando as informações de crominância e limitando artefatos visuais.

III. METODOLOGIA

Esta seção descreve o pipeline experimental adotado para comparar os três detectores faciais sob diferentes condições de iluminação.

A. Dataset

O experimento utiliza duas fontes de imagens complementares.

A primeira é um conjunto próprio coletado pelos autores, composto por fotografias de rostos capturadas em quatro condições de iluminação controladas: (i) iluminação frontal adequada, (ii) baixa luminosidade, (iii) iluminação lateral e (iv) superexposição. As imagens foram obtidas com smartphone em ambiente interno, mantendo posição e distância fixas para isolar o fator de iluminação. Cada condição conta com aproximadamente 5 imagens, totalizando cerca de 20 amostras.

A segunda fonte é o dataset público **Labeled Faces in the Wild (LFW)** [7], amplamente utilizado como benchmark em tarefas de detecção e reconhecimento facial. Do LFW, foram selecionadas imagens representativas de condições variadas de iluminação para complementar o conjunto de avaliação e permitir uma comparação com cenários mais diversos.

Para o subconjunto LFW, as *bounding boxes* de *ground truth* foram geradas automaticamente pelo próprio Haar Cascade, seguindo a mesma estratégia adotada em trabalhos que utilizam o LFW com alinhamento profundo. Para o dataset próprio, as anotações foram geradas automaticamente com o HOG+SVM como detector primário, com fallback para YuNet e Haar nos casos em que o HOG não detectou nenhuma face — o que ocorreu em apenas uma imagem (iluminação escura, resolvida com CLAHE+HOG). Essa abordagem de auto-anotação introduz viés em favor dos detectores usados como referência, o que é reconhecido como limitação deste trabalho.

B. Pré-processamento

Cada imagem é processada em duas versões: sem pré-processamento (imagem bruta) e com aplicação de CLAHE. O CLAHE é aplicado no canal de luminosidade da imagem convertida para o espaço de cores YCrCb, com *clipLimit* de 2.0 e grade de 8×8 , seguindo a implementação disponível no OpenCV [5]. Essa abordagem permite avaliar isoladamente o efeito do pré-processamento sobre cada detector.

TABLE I
F1-SCORE NO LFW SUBSET ($\text{IoU} \geq 0,5$, $n = 25/\text{CONDIÇÃO}$)

Detector	Condição	F1 (Raw)	F1 (CLAHE)
Haar Cascade	Boa luz	0.962	0.960
	Escuro	0.893	0.778
	Lateral	0.980	0.939
	Superexp.	0.962	0.902
HOG+SVM	Boa luz	0.898	0.920
	Escuro	0.720	0.745
	Lateral	0.939	0.917
	Superexp.	0.923	0.923
YuNet	Boa luz	0.923	0.923
	Escuro	0.717	0.717
	Lateral	0.962	0.943
	Superexp.	0.906	0.906

C. Implementação dos Detectores

Os três detectores são implementados em Python, utilizando as bibliotecas OpenCV e dlib.

O **Haar Cascade** utiliza o classificador pré-treinado `haarcascade_frontalface_default.xml`, disponível nativamente no OpenCV [1].

O **HOG+SVM** é implementado com o detector frontal pré-treinado da biblioteca dlib (`get_frontal_face_detector`), que aplica o descritor HOG com janela deslizante sobre a imagem em escala de cinza, seguindo [2].

O **YuNet** é carregado via módulo `cv2.FaceDetectorYN`, utilizando o modelo `face_detection_yunet_2023mar.onnx` [4]. O limiar de confiança foi ajustado para `score_threshold = 0.7` (padrão OpenCV: 0.9), necessário para acomodar imagens de alta resolução onde os scores tendem a ser ligeiramente inferiores ao padrão calibrado para imagens pequenas.

D. Métricas de Avaliação

O desempenho de cada detector é avaliado pelas métricas de **Precisão**, **Recall** e **F1-score**, calculadas com base na intersecção sobre a união (IoU) entre a detecção e o *ground truth*, adotando limiar de $\text{IoU} \geq 0,5$ para considerar uma detecção como verdadeiro positivo. Além disso, o **tempo médio de inferência** por imagem é registrado para avaliar a viabilidade de uso em sistemas de tempo real.

IV. RESULTADOS

As Tabelas I e II apresentam o F1-score obtido em cada dataset. O LFW subset conta com 25 imagens por condição (100 no total), enquanto o dataset próprio possui entre 4 e 6 imagens por condição (19 no total) — volume insuficiente para conclusões estatísticas robustas, mas útil para validar o comportamento dos detectores em imagens reais de alta resolução (1920×1080 px).

A Fig. 1 compara visualmente os dois datasets. O tempo médio de inferência, medido no LFW (Fig. 2), foi de $\approx 2,1$ ms para o YuNet, $\approx 3,4$ ms para o Haar e $\approx 9,2$ ms para o HOG+SVM.

TABLE II
F1-SCORE NO DATASET PRÓPRIO ($\text{IoU} \geq 0,5$, $n = 4-6/\text{CONDIÇÃO}$)

Detector	Condição	F1 (Raw)	F1 (CLAHE)
Haar Cascade	Boa luz	1.000	1.000
	Escuro	1.000	0.000
	Lateral	0.667	0.000
	Superexp.	1.000	1.000
HOG+SVM	Boa luz	1.000	1.000
	Escuro	0.000	1.000
	Lateral	0.000	0.000
	Superexp.	1.000	1.000
YuNet	Boa luz	0.000	1.000
	Escuro	0.000	0.000
	Lateral	1.000	1.000
	Superexp.	1.000	1.000




Fig. 1. F1-score por detector, condição e passagem nos dois datasets.




Fig. 2. Tempo médio de inferência por detector (LFW subset).

V. DISCUSSÃO

Ao analisar os resultados, alguns comportamentos chamaram mais a atenção do que esperávamos. O mais recorrente foi a queda de desempenho na condição escuro em todos os detectores, o que já era esperado pela literatura [6], mas a magnitude da queda variou bastante entre os métodos.

No LFW, o **Haar Cascade** foi o que melhor lidou com iluminação lateral ($F1 = 0.980$ sem CLAHE), chegando a recall perfeito. Porém, o CLAHE piorou os resultados na condição escuro: o F1 caiu de 0.893 para 0.778, porque a equalização amplificou texturas escuras no fundo, gerando falsos positivos

extras (de 6 para 8 FPs). Esse efeito apareceu ainda mais forte no dataset próprio, onde o Haar com CLAHE chegou a $F1=0.000$ na condição lateral — duas detecções falsas e nenhum verdadeiro positivo.

O **HOG+SVM** surpreendeu negativamente na condição lateral do dataset próprio: $F1=0.000$ em ambas as passagens. No LFW esse cenário havia retornado $F1=0.939$, o que mostra que as imagens próprias capturadas pelos autores tinham uma iluminação lateral mais severa do que as imagens do LFW classificadas com essa condição. Por outro lado, o CLAHE ajudou o HOG na condição escuro do próprio (de $F1=0.000$ para 1.000), o único caso em que o pré-processamento reverteu completamente uma falha de detecção.

O **YuNet** foi o detector mais rápido ($\approx 2,1$ ms no LFW) e apresentou comportamento mais estável entre condições no LFW. No dataset próprio, porém, falhou em todas as imagens escuras ($F1=0.000$), mesmo com CLAHE. Durante a implementação, descobrimos que o limiar de confiança padrão do OpenCV (0.9) era alto demais para imagens de alta resolução: uma face claramente visível na condição bright recebia score 0.892 e era descartada. Reduzir o limiar para 0.7 resolveu esse problema nas condições com iluminação adequada, mas não foi suficiente para o cenário escuro, onde o modelo simplesmente não encontrava a face.

Quanto às **limitações**, o dataset próprio é pequeno demais (4–6 imagens por condição) para tirar conclusões gerais, e os resultados binários ($F1 = 0$ ou 1) refletem mais a variabilidade individual das fotos do que tendências reais dos detectores. Além disso, como as *bounding boxes* de GT foram geradas automaticamente pelos próprios detectores, existe viés que favorece o método usado como anotador.

VI. CONCLUSÃO

Neste trabalho comparamos o desempenho de três detectores faciais — Haar Cascade, HOG+SVM e YuNet — sob quatro condições de iluminação, usando tanto um subconjunto do LFW quanto um dataset próprio coletado pelos autores.

Os resultados confirmam que iluminação escura é o maior desafio para os três métodos. O CLAHE teve efeito imprevisível: ajudou o HOG em alguns cenários, mas piorou o Haar em outros, especialmente quando o fundo escuro gerou falsos positivos após a equalização. O YuNet se mostrou a opção mais rápida e relativamente consistente no LFW, mas exigiu ajuste do limiar de confiança para funcionar com imagens de alta resolução — algo que não estava documentado de forma clara.

Uma dificuldade prática que encontramos foi a construção do *ground truth*: usar o próprio detector para gerar as anotações introduz viés e limita a imparcialidade da avaliação. Para trabalhos futuros, seria importante anotar manualmente as imagens e ampliar o dataset próprio para pelo menos 20 imagens por condição, viabilizando uma análise mais confiável. Explorar detectores mais robustos, como o MTCNN ou o RetinaFace, também seria uma continuidade natural deste estudo.

AGRADECIMENTOS

Os autores agradecem ao corpo docente da Graduação em Ciência da Computação do IDP pelo suporte e orientação ao longo do desenvolvimento deste trabalho.

REFERENCES

- [1] P. Viola and M. J. Jones, “Rapid object detection using a boosted cascade of simple features,” *Proc. IEEE CVPR*, vol. 1, pp. I-511–I-518, 2001.
- [2] N. Dalal and B. Triggs, “Histograms of oriented gradients for human detection,” *Proc. IEEE CVPR*, vol. 1, pp. 886–893, 2005.
- [3] K. Zhang, Z. Zhang, Z. Li, and Y. Qiao, “Joint face detection and alignment using multitask cascaded convolutional networks,” *IEEE Signal Processing Letters*, vol. 23, no. 10, pp. 1499–1503, 2016.
- [4] W. Wu, H. Peng, and S. Yu, “YuNet: A tiny millisecond-level face detector,” *Machine Intelligence Research*, vol. 20, no. 5, pp. 656–665, 2023.
- [5] K. Zuiderveld, “Contrast limited adaptive histogram equalization,” *Graphics Gems IV*, Academic Press, pp. 474–485, 1994.
- [6] Y. Adini, Y. Moses, and S. Ullman, “Face recognition: The problem of compensating for changes in illumination direction,” *IEEE Transactions on Pattern Analysis and Machine Intelligence*, vol. 19, no. 7, pp. 721–732, 1997.
- [7] G. B. Huang, M. Ramesh, T. Berg, and E. Learned-Miller, “Labeled faces in the wild: A database for studying face recognition in unconstrained environments,” University of Massachusetts, Amherst, Tech. Rep. 07-49, 2007.