

Análise Comparativa de Técnicas de Detecção Facial sob Variações de Iluminação para Aplicações em Segurança

Comparative Analysis of Facial Detection Techniques under Illumination Variations for Security Applications

Rafael Cândido, Lucas Tourinho, Gabriella Pereira, Lucas Rocha

Abstract—Facial detection is one of the most fundamental tasks in computer vision, with direct applications in security, access control, and surveillance. Despite significant advances in the field, illumination variation remains one of the primary practical challenges: algorithms that perform well in controlled environments frequently fail in real-world conditions, where low light, lateral illumination, or overexposure are common. This paper presents a comparative analysis of three facial detection approaches — Haar Cascade, HOG+SVM, and a lightweight Convolutional Neural Network (YuNet) — evaluated on images captured under four controlled illumination conditions. The study also investigates the impact of Contrast Limited Adaptive Histogram Equalization (CLAHE) preprocessing on each method. Experiments are conducted in Python using OpenCV and scikit-image, measuring precision, recall, F1-score, and average inference time per image. Results indicate that CNN-based methods are more robust to adverse lighting, while classical detectors benefit more significantly from CLAHE preprocessing.

Index Terms—Facial Detection, Image Processing, Illumination, Haar Cascade, HOG+SVM, Convolutional Neural Network, CLAHE, OpenCV, Security.

RESUMO

A detecção facial é uma das tarefas mais fundamentais em visão computacional, com aplicações diretas em segurança, controle de acesso e vigilância. Apesar dos avanços na área, a variação de iluminação ainda representa um dos principais desafios práticos. Este trabalho apresenta uma análise comparativa entre três técnicas de detecção facial — Haar Cascade, HOG+SVM e uma rede neural convolucional leve (YuNet) — avaliadas sobre imagens capturadas em quatro condições de iluminação distintas, com e sem a aplicação do pré-processamento CLAHE. Os experimentos são conduzidos em Python com as bibliotecas OpenCV e scikit-image.

Palavras-chave: Detecção Facial, Processamento de Imagens, Iluminação, Haar Cascade, HOG+SVM, Rede Neural Convolucional, CLAHE, OpenCV, Segurança.

I. INTRODUÇÃO

Sistemas de detecção facial são amplamente utilizados em aplicações de segurança, como controle de acesso, vigilância e autenticação biométrica. A capacidade de identificar a presença de um rosto em uma imagem de forma rápida e confiável é um pré-requisito para qualquer pipeline de

reconhecimento facial, e seu desempenho impacta diretamente a eficácia do sistema como um todo.

Um dos fatores que mais afeta essa confiabilidade é a variação de iluminação. Em ambientes reais, dificilmente as condições de luz são controladas: câmeras de segurança operam em ambientes internos com iluminação artificial irregular, em áreas externas sujeitas a contra-luz, ou em locais com pouca luminosidade [6]. Nesses cenários, detectores que apresentam bom desempenho em condições ideais podem falhar de forma significativa.

Ao longo das últimas décadas, diferentes abordagens foram desenvolvidas para o problema de detecção facial. Viola e Jones [1] propuseram um detector baseado em características de Haar e classificadores em cascata, que se tornou referência pela sua velocidade de processamento. Dalal e Triggs [2] introduziram os Histogramas de Gradientes Orientados (HOG) combinados com máquinas de vetores de suporte (SVM), com maior robustez a variações de posição. Mais recentemente, abordagens baseadas em redes neurais convolucionais profundas passaram a dominar os benchmarks da área, como o MTCNN [3] e o YuNet [4], este último integrado diretamente ao OpenCV com foco em eficiência computacional.

Para mitigar os efeitos da iluminação sobre a qualidade das imagens, técnicas de pré-processamento como a Equalização Adaptativa de Histograma com Limite de Contraste (CLAHE) [5] têm sido amplamente empregadas. O CLAHE melhora o contraste local da imagem sem amplificar ruído de forma excessiva, tornando-se uma opção interessante como etapa anterior à detecção.

Neste contexto, este trabalho tem como objetivo comparar o desempenho dos detectores Haar Cascade, HOG+SVM e YuNet em imagens com quatro condições distintas de iluminação, avaliando também o impacto do pré-processamento CLAHE sobre cada método. O restante do artigo está organizado da seguinte forma: a Seção II apresenta a fundamentação teórica; a Seção III descreve a metodologia adotada; a Seção IV apresenta os resultados; a Seção V discute os achados; e a Seção VI conclui o trabalho.

II. FUNDAMENTAÇÃO TEÓRICA

[A ser desenvolvida.]

III. METODOLOGIA

Esta seção descreve o pipeline experimental adotado para comparar os três detectores faciais sob diferentes condições de iluminação.

A. Dataset

O experimento utiliza duas fontes de imagens complementares.

A primeira é um conjunto próprio coletado pelos autores, composto por fotografias de rostos capturadas em quatro condições de iluminação controladas: (i) iluminação frontal adequada, (ii) baixa luminosidade, (iii) iluminação lateral e (iv) superexposição. As imagens foram obtidas com smartphone em ambiente interno, mantendo posição e distância fixas para isolar o fator de iluminação. Cada condição conta com aproximadamente 5 imagens, totalizando cerca de 20 amostras.

A segunda fonte é o dataset público **Labeled Faces in the Wild (LFW)** [7], amplamente utilizado como benchmark em tarefas de detecção e reconhecimento facial. Do LFW, foram selecionadas imagens representativas de condições variadas de iluminação para complementar o conjunto de avaliação e permitir uma comparação com cenários mais diversos.

Todas as imagens foram anotadas manualmente com *bounding boxes* delimitando a região do rosto, servindo como *ground truth* para o cálculo das métricas.

B. Pré-processamento

Cada imagem é processada em duas versões: sem pré-processamento (imagem bruta) e com aplicação de CLAHE. O CLAHE é aplicado no canal de luminosidade da imagem convertida para o espaço de cores YCrCb, com *clipLimit* de 2.0 e grade de 8×8 , seguindo a implementação disponível no OpenCV [5]. Essa abordagem permite avaliar isoladamente o efeito do pré-processamento sobre cada detector.

C. Implementação dos Detectores

Os três detectores são implementados em Python, utilizando as bibliotecas OpenCV e scikit-image.

O **Haar Cascade** utiliza o classificador pré-treinado `haarcascade_frontalface_default.xml`, disponível nativamente no OpenCV [1].

O **HOG+SVM** é implementado com o detector de pessoas da scikit-image como base estrutural, adaptado para detecção facial por meio do descritor HOG com parâmetros `orientations=9`, `pixels_per_cell=(8,8)` e `cells_per_block=(2,2)`, seguindo [2].

O **YuNet** é carregado via módulo `cv2.FaceDetectorYN`, utilizando o modelo `face_detection_yunet_2023mar.onnx` [4]. Por ser integrado ao OpenCV, dispensa dependências externas e oferece inferência eficiente.

D. Métricas de Avaliação

O desempenho de cada detector é avaliado pelas métricas de **Precisão**, **Recall** e **F1-score**, calculadas com base na interseção sobre a união (*IoU*) entre a detecção e o *ground*

truth, adotando limiar de $\text{IoU} \geq 0,5$ para considerar uma detecção como verdadeiro positivo. Além disso, o **tempo médio de inferência** por imagem é registrado para avaliar a viabilidade de uso em sistemas de tempo real.

IV. RESULTADOS

[A ser preenchido após os experimentos.]

V. DISCUSSÃO

[A ser desenvolvida.]

VI. CONCLUSÃO

[A ser desenvolvida.]

AGRADECIMENTOS

[A ser desenvolvida.]

REFERENCES

- [1] P. Viola and M. J. Jones, "Rapid object detection using a boosted cascade of simple features," *Proc. IEEE CVPR*, vol. 1, pp. I-511–I-518, 2001.
- [2] N. Dalal and B. Triggs, "Histograms of oriented gradients for human detection," *Proc. IEEE CVPR*, vol. 1, pp. 886–893, 2005.
- [3] K. Zhang, Z. Zhang, Z. Li, and Y. Qiao, "Joint face detection and alignment using multitask cascaded convolutional networks," *IEEE Signal Processing Letters*, vol. 23, no. 10, pp. 1499–1503, 2016.
- [4] W. Wu, H. Peng, and S. Yu, "YuNet: A tiny millisecond-level face detector," *Machine Intelligence Research*, vol. 20, no. 5, pp. 656–665, 2023.
- [5] K. Zuiderveld, "Contrast limited adaptive histogram equalization," *Graphics Gems IV*, Academic Press, pp. 474–485, 1994.
- [6] Y. Adini, Y. Moses, and S. Ullman, "Face recognition: The problem of compensating for changes in illumination direction," *IEEE Transactions on Pattern Analysis and Machine Intelligence*, vol. 19, no. 7, pp. 721–732, 1997.
- [7] G. B. Huang, M. Ramesh, T. Berg, and E. Learned-Miller, "Labeled faces in the wild: A database for studying face recognition in unconstrained environments," University of Massachusetts, Amherst, Tech. Rep. 07-49, 2007.